Benchmark Comparative des Modèles LLM Ollama

Évaluation d'inférence locale pour la qualification intelligente de briefs (Projet SENS-FLOW)

PROJET	CIBLE MATÉRIELLE	MODÈLE RETENU	DATE D'ÉVALUATION
SENS-FLOW / Givaudan	**CPU Only (8 Go RAM)**	**Qwen 1.5B / 3B (Q4_K_M)**	**Novembre 2026**

1. Contexte & Contraintes d'Infrastructure

Le pipeline d'extraction sémantique du projet **SENS-FLOW** nécessite l'intégration d'un modèle de langage (LLM) exécuté localement via Ollama pour analyser des briefs clients non structurés. L'environnement cible est contraint par une infrastructure légère sans GPU dédié (8 Go de RAM vive, calcul exclusivement sur CPU).

2. Tableau Comparatif des Modèles Évalués sur Ollama

Modèle	Taille / Quant	RAM Utilisée	Vitesse (CPU 8Go)	Extraction Structurée	Statut d'Éligibilité
Qwen (1.5B / 3B)	**1.5B - 3B (q4_K_M)**	**1.8 Go - 2.4 Go**	**14 - 22 tok/s**	**Excellente (JSON strict)**	**RECOMMANDÉ (Choix)**
Llama 3.2 (1B / 3B)	1B - 3B (q4_K_M)	1.3 Go - 2.2 Go	16 - 25 tok/s	Bonne	**VALIDE**
Phi-3 Mini	3.8B (q4_K_M)	2.7 Go	8 - 12 tok/s	Moyenne (Sensible au format)	**ACCEPTABLE**
Mistral 7B	7B (q4_K_M)	5.2 Go (Swap system)	1.5 - 3 tok/s	Excellente	**REJETÉ (Sature RAM)**

3. Analyse Métrique & Rationale du Choix (Qwen)

Bien que **Mistral 7B** soit la référence industrielle pour la compréhension sémantique française, sa taille (4.5 Go de footprint + surcharge d'exécution de 1 Go) consomme plus de 80% de la mémoire disponible sur la machine hôte. Cela déclenche un ralentissement critique par swapping réseau/disque.

Le choix de la famille **Qwen (1.5B / 3B)** (ou Qwen 2.5 / compact) offre le meilleur compromis opérationnel pour le prototype :

- **Consommation mémoire maîtrisée :** L'empreinte mémoire inférieure à 2.5 Go laisse plus de 5 Go de RAM disponibles pour le système d'exploitation, l'engine dbt et le serveur d'API.
- **Fluidité conversationnelle sur CPU :** Une vitesse moyenne de 18 tokens/sec permet d'exécuter la qualification du brief en moins de 3 secondes.
- **Respect strict des Schémas JSON :** Capacité à extraire sans hallucination les 6 champs obligatoires du brief (prix cible, allergènes, application, volume, profil olfactif, contraintes).

4. Recommandation d'Exécution Ollama

Commande de Déploiement Local

Pour exécuter le modèle retenu sans risque de dépassement mémoire sur la machine de test :

```
ollama run qwen2.5:1.5b-instruct-q4_K_M
```